


1^η Principal Component Analysis (PCA)

Αρχικά διαβάστηκαν τα παρακάτω δείγματα. Τα δείγματα κανονικοποιήθηκαν με μέση τιμή μηδέν

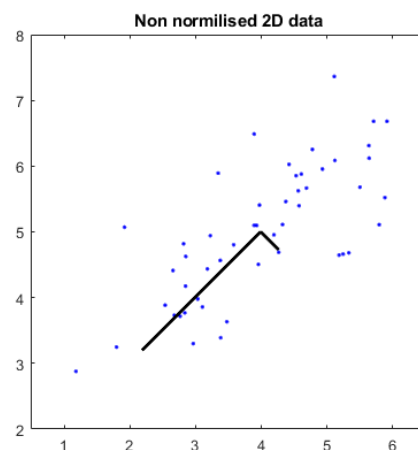


Σχήμα 1: Raw 2D data

και διασπορά 1, σύμφωνα με τον τύπο:

$$X_{norm} = \frac{(X_i - \mu_x)}{\sigma_i}$$


Στην συνέχεια υπολογίζονται οι κύριες συνηστώσεις PCA οι οποίες εξάγονται από τον covariance matrix των δεδομένων και αφού ταξινομηθούν επιστρέφονται σε μορφή πίνακα και απικονίζονται στα αρχικά δεδομένα. Στην συνέχεια γίνεται η προβολή των 2D δεδομένων σε μια διάσταση



Σχήμα 2: Raw 2D data with PCA

σύμφωνα με τις οδηγίες (γίνεται χρήση των eigenvectors που μας ενδιαφέρουν, στο παράδειγμα, μόνο του πρώτου).

Τα κανονικοποιημένα δεδομένα έχοντας γίνει η προβολή τους:



Σχήμα 3: Projection of normalized data

Στην συνέχεια πραγματοποιήθηκαν τα παραπάνω βήματα σε δεδομένα πολλών διαστάσεων. Για να γίνει αντιληπτός ο τρόπος με τον οποίο ο PCA λειτουργεί θα παρουσιαστούν δεδομένα με διαφορετικές διαστάσεις προβολής. Αρχικά για 10 μεταβλητές έχουμε



Σχήμα 4: Recovered data for $K = 10$

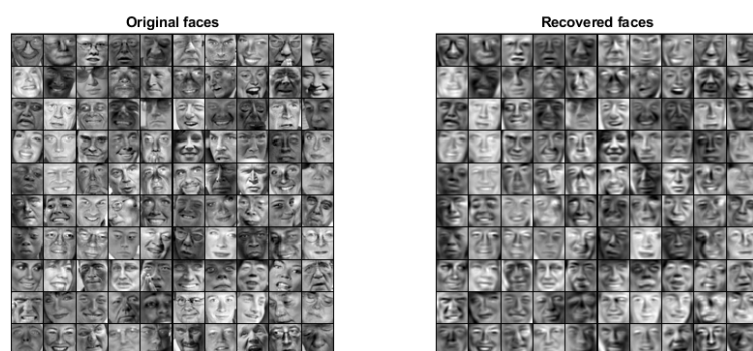
Παρατηρείται ίδη, ότι, από την πληροφορία που κρατείτε στις 10 πρώτες “μεταβλητές” μπορούν να σχηματιστούν τα χαρακτηριστικά των προσώπων μαζί με κάποιες λεπτομέρειες. Για $K = 50$ αρχίζουν να εμφανίζονται λεπτομέρειες ποιο ευδιάκριτες αλλά και που δεν υπήρχαν πριν. Για



Σχήμα 5: Recovered data for $K = 50$

$K = 100, 200$ οι εικόνες γίνονται πιο λεπτομερείς και πλησιάζουν αρκετά της αρχικές.

Μπορούμε να καταλάβουμε πως μεγάλος όγκος πληροφορίας κρατείται στα πρώτα principal components.



Σχήμα 6: Recovered data for $K = 100$

Δεν έχει νόημα να εμφανιστούν παραπάνω περιπτώσεις μιας και η πληροφορία που αναχτούμε,

κάθε φορά, είναι συγκριτικά μικρή σε σχέση με τις αρχικές.

2^η Σχεδιασμός ταξινομητή LDA

Για τις ισοπίθανες κατηγορίες:

$$\begin{aligned}\omega_1 &= \mathcal{N}(\mu_1, \sigma_1^2) \quad , \quad \mu_1 = \begin{bmatrix} -5 \\ 5 \end{bmatrix} \quad , \quad \sigma_1 = \begin{bmatrix} 11 & 9 \\ 9 & 11 \end{bmatrix} \\ \omega_2 &= \mathcal{N}(\mu_2, \sigma_2^2) \quad , \quad \mu_2 = \begin{bmatrix} 10 \\ 15 \end{bmatrix} \quad , \quad \sigma_2 = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}.\end{aligned}$$

Για να υπολογιστεί το διάνυσμα προβολής w αρχικά πρέπει να υπολογιστεί ο πίνακας διασποράς εντός των κατηγοριών (μιας και μιλάμε για μόλις 2 κλάσεις), S_w :

$$S_w = \Sigma_{i=1}^C P_i \Sigma_i = \frac{1}{2}(\Sigma_1 + \Sigma_2) = \frac{1}{2} \left(\begin{bmatrix} 11 & 9 \\ 9 & 11 \end{bmatrix} + \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \right) = \begin{bmatrix} 6.5 & 4.5 \\ 4.5 & 6.5 \end{bmatrix}$$

Με βάση τον S_w μπορεί να υπολογιστεί το διάνυσμα ως εξής:

$$\begin{aligned}w &= S_w^{-1}(\mu_1 - \mu_2) = \frac{1}{6.5^2 - 4.5^2} \begin{bmatrix} 6.5 & -4.5 \\ -4.5 & 6.5 \end{bmatrix} \cdot \begin{bmatrix} -15 \\ -10 \end{bmatrix} \Rightarrow \\ w &= \frac{1}{22} \begin{bmatrix} -52.5000 \\ 2.5 \end{bmatrix} = \begin{bmatrix} -2.3864 \\ 0.1136 \end{bmatrix}\end{aligned}$$

Τέλος θα κανονικοποιηθεί το w και θα έχουμε:


$$w_{normalised} = \frac{w}{\|w\|} = \frac{w}{\sqrt{(-2.3864)^2 + (0.1136)^2}} = \frac{w}{2.3891} \Rightarrow$$

$$w_{normalised} = \begin{bmatrix} -0.9988 \\ 0.0476 \end{bmatrix}$$

3^η LDA vs PCA

Σε πρώτη φάση έγινε η κανονικοποίηση των δεδομένων (όμοια με άσκηση 1) και έπειτα υπολογίστηκε η βέλτηστη διεύθυνση για την οποία τα δεδομένα παρουσιάζουν την μέγιστη διακριτικότητα μεταξύ των κλάσεων. Ουσιαστικά προσπαθούμε να μεγιστοποιήσουμε την μέση τιμή καθώς και να μειώσουμε την διασπρά της κάθε κλάσης. Αυτή η πληροφορία αποθηκεύεται σε διάνυσμα.


Για τα αρχικά δεδομένα, έχουμε την εξής προβολή στον στην μια διάσταση. Μπορούμε να πα-



Σχήμα 7: LDA 2D to 1D

ρατηρήσουμε εύκολα, την διακριτικότητα μεταξύ των κλάσεων στην μια διάσταση.

Αν προσπαθήσουμε να εφαρμόσουμε *PCA* στα ίδια δεδομένα παρατηρούμε χειρότερη διακριτικότητα.




Σχήμα 8: PCA 2D to 1D

Οι κλάσεις στην μια διάσταση, παρουσιάζουν χειρότερη διακριτικότητα σε σχέση με πριν. Χονδρικά αυτό συμβαίνει λόγω του ότι ο *PCA* κάνει σύνοψη δεδομένων. Δουλεύοντας με τα ιδιοδιανύσματα και τις ιδιοτιμές προπαθή να περιγράψει καλύτερα μια κλάση χωρίς να την πάρει υπόψη του για την εξαγωγή των principal components. Αντίθετα, ο *LDA* προσπαθεί να τροποποιήσει τα δεδομένα ώστε οι κλάσεις, εκτός των άλλων, να απέχουν μεταξύ τους.


Για την εφαρμογή των δεδομένων σε δεδομένα παραπάνω κλάσεων, ακολουθήθηκε η ίδια λογική αλλά για περισσότερες διαστάσεις.

Ποιο συγκεκριμένα για τα παρακάτω δείγματα,




Σχήμα 9: Samples of data

Εφαρμόζοντας τον αλγόριθμο, παίρνουμε το βέλτιστο διάνυσμα. Με την προβολή των δεδομένων, στις 2 διαστάσεις σε αυτό, έχουμε



Σχήμα 10: Data Clasification after LDA at 2d

Αντοίστουχη διαχωριστικότητα θα έχουμε και στην μία διάσταση με αποτελέσματα:



Σχήμα 11: Data Clasification after LDA at 2d

Σε αυτό το σημείο να αναφερθεί ότι τα αρχικά δεδομένα διέφεραν από αυτά που διέθετε η matlab μιας και απαιτούσε την χρήση βιβλιοθηκών που δεν είχα.

4^η Bayes

Για τις κατηγορίες:

$$\omega_1 = \mathcal{N}(\mu_1, \Sigma_1) \quad , \quad \mu_1 = \begin{bmatrix} 3 \\ 3 \end{bmatrix} \quad , \quad \Sigma_1 = \begin{bmatrix} 1.2 & -0.4 \\ -0.4 & 1.2 \end{bmatrix}$$

$$\omega_2 = \mathcal{N}(\mu_2, \Sigma_2) \quad , \quad \mu_2 = \begin{bmatrix} 6 \\ 6 \end{bmatrix} \quad , \quad \Sigma_2 = \begin{bmatrix} 1.2 & 0.4 \\ 0.4 & 1.2 \end{bmatrix}.$$

Ανάλογα με την παρατήρηση θα επιλεχθεί η αντίστοιχη κατηγορία.

- Χρησιμοποιώντας τον κανόνα Bayes:

$$P(x)P(\omega_i | x) = P(x | \omega_i)P(\omega_i) \Rightarrow P(\omega_i | x) = \frac{P(x | \omega_i)P(\omega_i)}{P(x)}, \quad \omega \in [1, 2]$$

Το σύνορο απόφασης θα βρίσκεται στο σημείο όπου

$$P(\omega_1 | x) = P(\omega_2 | x) \Rightarrow \frac{P(x | \omega_1)P(\omega_1)}{\cancel{P(x)}} = \frac{P(x | \omega_2)P(\omega_2)}{\cancel{P(x)}} \Rightarrow$$

$$P(x | \omega_1)P(\omega_1) = P(x | \omega_2)P(\omega_2) \Rightarrow$$

$$\frac{P(\omega_1)}{P(\omega_2)} = \frac{P(x | \omega_2)}{P(x | \omega_1)}$$

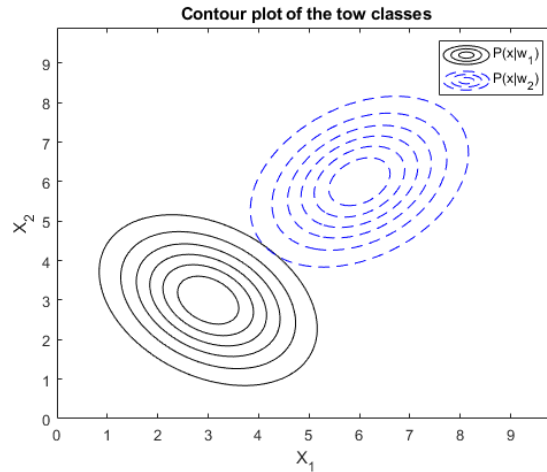
Γνωρίζουμε όμως, τις κατανομές της κάθε κλάσης:

$$P(x | \omega_i) = \frac{\exp \left\{ -\frac{1}{2}(x - \mu_i)^T \Sigma_i^{-1} (x - \mu_i) \right\}}{|\Sigma_i|^{\frac{1}{2}} 2\pi}$$

Άρα:

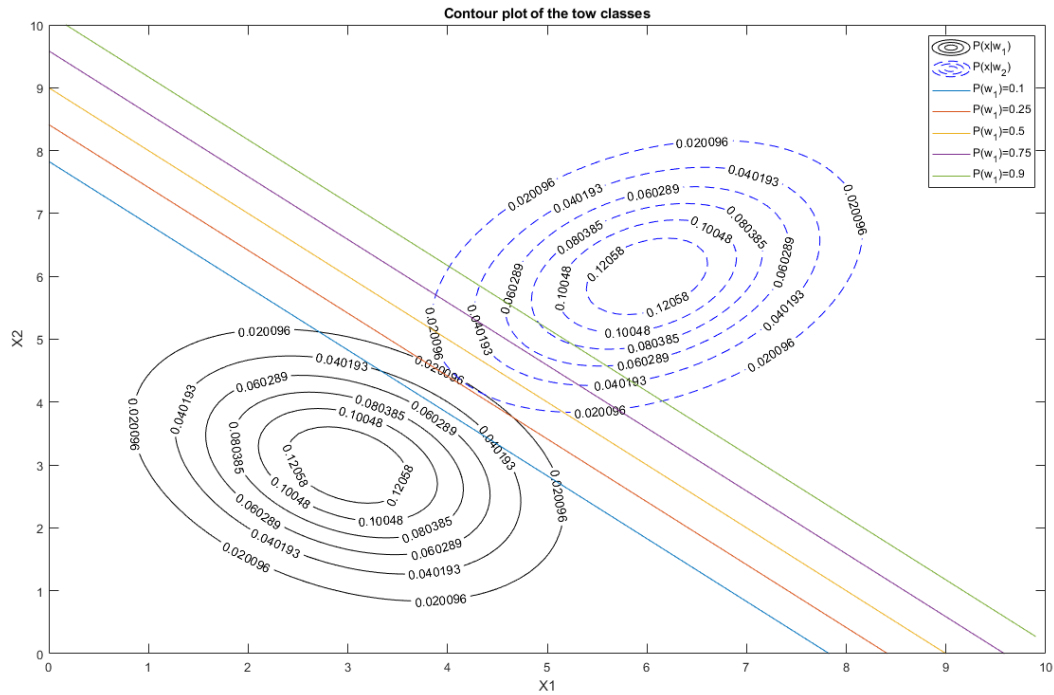
$$\begin{aligned}
\frac{P(\omega_1)}{P(\omega_2)} &= \frac{P(x | \omega_2)}{P(x | \omega_1)} \Rightarrow \\
\ln \left(\frac{P(\omega_1)}{P(\omega_2)} \right) &= \ln \left(\frac{P(x | \omega_2)}{P(x | \omega_1)} \right) \Rightarrow \\
\ln(P(\omega_1)) - \ln(P(\omega_2)) &= \ln(P(x | \omega_2)) - \ln(P(x | \omega_1)) = \\
\ln \left(\frac{\exp \left\{ -\frac{1}{2}(x - \mu_2)^T \Sigma_2^{-1} (x - \mu_2) \right\}}{|\Sigma_2|^{\frac{1}{2}} 2\pi} \right) &- \ln \left(\frac{\exp \left\{ -\frac{1}{2}(x - \mu_1)^T \Sigma_1^{-1} (x - \mu_1) \right\}}{|\Sigma_1|^{\frac{1}{2}} 2\pi} \right) = \\
\left(-\frac{1}{2}(x - \mu_2)^T \Sigma_2^{-1} (x - \mu_2) \right) &- \ln(|\Sigma_2|^{\frac{1}{2}} 2\pi) - \left(-\frac{1}{2}(x - \mu_1)^T \Sigma_1^{-1} (x - \mu_1) \right) + \ln(|\Sigma_1|^{\frac{1}{2}} 2\pi) = \\
\frac{1}{2} \left((x - \mu_1)^T \Sigma_1^{-1} (x - \mu_1) - (x - \mu_2)^T \Sigma_2^{-1} (x - \mu_2) \right) &= \\
\frac{1}{2} \left([x_1 - 3 \quad x_2 - 3] \cdot \begin{bmatrix} 0.9375 & 0.3125 \\ 0.3125 & 0.9375 \end{bmatrix} \cdot \begin{bmatrix} x_1 - 3 \\ x_2 - 3 \end{bmatrix} - \dots \right) &= \\
\cancel{0.9375x_1^2} + 0.625x_1x_2 - \cancel{7.5x_1} + \cancel{0.9375x_2^2} + 22.5 - \cancel{7.5x_2} - & \\
\cancel{0.9375x_1^2} + 0.625x_1x_2 + \cancel{7.5x_1} - \cancel{0.9375x_2^2} - 45 + \cancel{7.5x_2} &= \\
1.25x_1x_2 - 22.5 \Rightarrow & \\
\frac{5(\ln(P(\omega_1)) - \ln(P(\omega_2)))}{4} + 18 = x_1x_2 \Rightarrow & \\
x_1 = \frac{\frac{5(\ln(P(\omega_1)) - \ln(P(\omega_2)))}{4} + 18}{x_2} &
\end{aligned}$$

- Οι ισοϋψείς καμπύλες των δεσμευμένων πιθανοτήτων:



Σχήμα 12: Samples of data

- Οι ισοϋφείς καμπύλες των δεσμευμένων πιθανοτήτων με τα σύνορα απόφασης : Παρατηρο-



Σχήμα 13: Samples of data


ύμε πως τα όρια είναι ανάλογα με την κάθε κατανομή. Για μικρό όριο της κλάσης w_1 είναι αντιστοίχως και μικρή η περιοχή κατανομής σε σχέση με την δεύτερη κλάση.

Στην περίπτωση που οι πίνακες συνδιακύμανσης είναι ίσοι, παύουν να μας ενδιαφέρουν οι τετραγωνικοί όροι καθώς δεν τους λαμβάνουμε υπ όψιν στις συγκρίσεις. Οι συναρτήσεις διάκρισης είναι γραμμικές και η περιοχή απόφασης μετακινείται προς την περιοχή με την μικρότερη πιθανότητα:

5^η Εξαγωγή χαρακτηριστικών και Bayes Classification

Αρχικά υπολογίστηκε το aspect ratio για κάθε εικόνα, κάθε κλάσης, (test και test) και αποθηκεύτηκε.

Ενδεικτικά κάποια από τα δεδομένα κατά τον υπολογισμό:



Σχήμα 14: Samples of data

Στην συνέχεια, έχοντας υπολογίσει τις prior πιθανότητες προσπαθούμε να φριάξουμε τις κατανομές τις κάθε κλάσης του ταξινομητή.

Υπολογίζουμε τις μέσες τιμές τις κάθε κλάσης ($\mu_{C1} = 0.468$ και $\mu_{C2} = 0.961$) και την διακύμανσή τους ($\sigma_{C1} = 0.199$ και $\sigma_{C1} = 0.1883$).

Έπειτα κατασκευάζουμε τις κατανομές τους ως εξής

$$P(\omega_i | x) = \frac{1}{\sigma_i \sqrt{2\pi}} \exp \left(-\frac{1}{2} \left(\frac{x - \mu_i}{\sigma_i} \right)^2 \right)$$

Γνωρίζοντας τις κατανομές κάθε κλάσης και άρα τον ταξινομητή, “περνάμε” εικόνα, από το test set από αυτόν και λαμβάνουμε τις πιθανότητες $P(x | \omega_1)$ (δεν είναι κανονικοποιημένες).

Τέλος, για κάθε εικόνα αποθηκεύουμε την κλάση που εμφανίζει την μέγιστη πιθανότητα και ελέγχουμε την εσφαλμένη ταξινόμηση, για καθε μια από αυτή.

Για σαν τελικά αποτελέσματα έχουμε τα παρακάτω

```
Applying Classification.
Total errors: 237 (0.109368%).
Class 1 errors: 120 (0.105727%).
Class 2 errors: 117 (0.113372%).
```

Σχήμα 15: Classification Errors

Παρατηρούμε πως η ταξινόμηση με βάση το ελάχιστο ορθογώνιο που περικλείει το κάθε ψηφίο είναι εμφανίζει σφάλμα της τάξεως του 10%

6^η Minimum risk

Για τον πίνακα ρίσκου $L = \begin{bmatrix} 0 & 0.5 \\ 1.0 & 0 \end{bmatrix}$ το κόστος πρόβλεψης ω_1 δεδομένου της ω_2 είναι $L_{12} = 0.5$ και αντίστοιχα δεδομένου ω_1 , το κόστος για ω_2 είναι $L_{21} = 1$.

Για να υπολογιστεί το όριο απόφασης με το μικρότερο ρίσκο θα πρέπει να υπολογιστεί το ρίσκο για κάθε κλάση.

$$R(\omega_1 | x) = \cancel{L_{11}P(\omega_1 | x)} \overset{0}{+} L_{12}P(\omega_2 | x)$$

$$R(\omega_2 | x) = \cancel{L_{22}P(\omega_2 | x)} \overset{0}{+} L_{21}P(\omega_1 | x)$$

Για το όριο:

$$\begin{aligned} L_{12}P(\omega_2 | x) &= L_{21}P(\omega_1 | x) \Rightarrow \\ L_{12}P(x | \omega_2)P(\omega_2) &= L_{21}P(x | \omega_1)P(\omega_1) \Rightarrow \\ \frac{P(x | \omega_2)}{P(x | \omega_1)} &= \frac{P(\omega_1)L_{21}}{L_{12}P(\omega_2)} = 2 \Rightarrow \\ \frac{x}{\sigma_2^2} \exp\left\{-\frac{x^2}{2\sigma_2^2}\right\} &= 2 \frac{x}{\sigma_1^2} \exp\left\{-\frac{x^2}{2\sigma_1^2}\right\} \Rightarrow \\ \frac{x}{4} \exp\left\{-\frac{x^2}{8}\right\} &= 2 \frac{x}{1} \exp\left\{-\frac{x^2}{2}\right\} \Rightarrow \\ \frac{1}{8} \exp\left\{-\frac{x^2}{8}\right\} &= \exp\left\{-\frac{x^2}{2}\right\} \xrightarrow{\ln()} \\ \ln\left(\frac{1}{8}\right) - \frac{x^2}{8} &= -\frac{x^2}{2} \Rightarrow \\ \ln(1) - \ln(2^3) &= \frac{x^2}{8} - \frac{x^2}{2} \Rightarrow \\ -2.08 &= \frac{-3x^2}{8} \Rightarrow x \simeq 2.35 \end{aligned}$$